

Evaluación de Paradigmas de Scheduling en Sistemas OFDMA bajo Heterogeneidad Espacial y de Tráfico

Alfonso García

Maestría en Ciencias de la Computación
Benemérita Universidad Autónoma de Puebla
Puebla, México
alfonso.089911@gmail.com

Resumen—El scheduler de enlace descendente es, en la práctica, el componente que decide si un usuario en el fondo de la celda recibe datos o queda ignorado mientras el vecino del frente monopoliza el canal. Elegir cuál paradigma usar no es trivial: siete algoritmos bien conocidos —clasificados según la taxonomía de Capozzi et al. [1]— se comportan de manera radicalmente distinta en función de cómo están distribuidos los usuarios y qué tipo de tráfico generan.

Este trabajo ejecuta 1,680 simulaciones en ns-3.47/LTE para cuantificar esas diferencias bajo cuatro condiciones combinadas de heterogeneidad espacial y de tráfico. Dos hallazgos van contra la intuición inicial: primero, la distribución clusterizada de usuarios afecta menos la equidad de lo esperado —la carga de la celda es el factor dominante para 6 de 7 schedulers—; segundo, M-LWDF, el algoritmo que más agresivamente protege los flujos con garantía de servicio (GBR), es también el que más reduce el throughput total de celda cuando el tráfico es heterogéneo (−31%). Lo que sí confirman los datos con alta significancia ($p < 0,001$, $d \approx 5$) es que M-LWDF y PSS superan a PF en equidad global cuando los usuarios están clusterizados y el tráfico mezcla GBR con best-effort: un resultado que tiene implicaciones directas para el despliegue en escenarios de tipo URLLC en redes LTE/5G.

Index Terms—OFDMA, scheduling, LTE, fairness, QoS, heterogeneidad espacial, tráfico heterogéneo, ns-3

I. INTRODUCCIÓN

Imagine una sala de espera hospitalaria conectada por LTE: algunas personas transmiten video de consulta telemédica (requieren baja latencia y bitrate garantizado), otras descargan datos de historiales (best-effort), y todos están físicamente agrupados lejos de la antena. El scheduler de la estación base debe decidir, cada milisegundo, a quién darle recursos. Esa decisión no es trivial, y su impacto sobre la experiencia de cada usuario depende tanto del algoritmo elegido como de las condiciones del entorno.

El problema de asignación de recursos en OFDMA ha generado docenas de propuestas desde los primeros años de LTE. Los *schedulers* (planificadores de recursos) —algoritmos que deciden a quién dar cada bloque de radio cada milisegundo— son el objeto de estudio de este trabajo. Los tres clásicos —Round Robin, Maximum Throughput y Proportional Fair— están documentados con precisión [2]. Capozzi et al. [1] organizaron la literatura en una taxonomía de cinco categorías

que es hoy el marco de referencia estándar. El problema es que casi toda esa literatura evalúa los schedulers en condiciones ideales: usuarios distribuidos uniformemente en la celda, tráfico homogéneo, un único tipo de servicio. En la práctica, los usuarios se agrupan geográficamente (hay más personas en el centro comercial que en el estacionamiento), y en la misma celda coexisten video, voz, gaming y tráfico de fondo.

Lo que no existe, hasta donde encontramos, es una evaluación sistemática que aísle por separado el efecto de la distribución espacial y el de la mezcla de tráfico sobre la *taxonomía completa* de schedulers, con suficientes repeticiones estadísticas para afirmar diferencias con confianza. Ese es exactamente el experimento que reportamos aquí: 7 schedulers, 4 condiciones combinadas, 20 repeticiones por configuración, en total 1,680 simulaciones en ns-3.47.

Los resultados tienen algunas sorpresas. Anticipábamos que los clusters de usuarios harían colapsar la equidad de los schedulers orientados a throughput, pero la realidad resultó más matizada. La distribución espacial importa menos de lo esperado; la carga de la celda importa más. Y M-LWDF, el más sofisticado de los algoritmos QoS-aware, resulta ser también el que más castiga el throughput total cuando el tráfico es heterogéneo. Discutimos por qué tiene sentido, y qué significa para la elección de scheduler en escenarios reales.

II. MARCO TEÓRICO

II-A. OFDMA y asignación de recursos en LTE

En LTE, el canal descendente (de la antena al teléfono) divide el espectro en bloques de recursos (RBs, *Resource Blocks*) de 180 kHz de ancho cada uno. Con 10 MHz de ancho de banda hay 50 RBs disponibles por TTI (Intervalo de Transmisión, *Transmission Time Interval*, de 1 ms de duración). El scheduler asigna estos RBs a usuarios individuales en cada TTI, guiándose por el CQI que cada usuario reporta: un valor de 1 a 15 que codifica la SINR recibida en cada RB. El número de bits que caben en un RB puede variar desde 2 (QPSK, $\text{SINR} < 3$ dB) hasta 14 (64-QAM, $\text{SINR} > 22$ dB) [3]. Esta variación es la que los schedulers channel-aware explotan: si dos usuarios compiten por el mismo RB, conviene dárselo al que tiene mejor CQI en ese instante.

La diversidad multiusuario surge precisamente de que el canal varía de forma *independiente* entre usuarios —el desvanecimiento (fading) que penaliza a uno en un RB dado no necesariamente penaliza a otro. Con fading activo, el scheduler puede asignar cada RB al usuario que lo aprovecha mejor en ese TTI, algo que en condiciones de canal estático (sin fading) es imposible: todos los UEs equidistantes tienen el mismo CQI y el scheduler no puede discriminar.

II-B. Métricas de evaluación

Throughput de celda (T_c): suma del throughput por usuario en Mbps.

Índice de Jain (J): medida de equidad de asignación de recursos [4]:

$$J(x_1, \dots, x_n) = \frac{(\sum_{i=1}^n x_i)^2}{n \cdot \sum_{i=1}^n x_i^2} \quad (1)$$

donde x_i es el throughput del usuario i . $J \in [1/n, 1]$; $J = 1$ indica equidad perfecta.

Retardo E2E (D): retardo medio extremo a extremo por flujo IP (FlowMonitor).

PLR: tasa de pérdida de paquetes = $(N_{tx} - N_{rx})/N_{tx}$ por flujo.

II-C. Taxonomía de Capozzi

Capozzi et al. [1] clasifican los schedulers LTE en cinco categorías. Este trabajo activa las tres relevantes para redes heterogéneas:

- **(i) Sin consciencia de canal ni de QoS** (*channel-unaware / QoS-unaware*): no usa información del canal ni garantías de servicio. Representantes: RR, BET.
- **(ii) Con consciencia de canal, sin QoS** (*channel-aware / QoS-unaware*): explota el CQI para mejorar eficiencia, pero no distingue entre tipos de flujo. Representantes: MT, TTA, PF.
- **(iii) Con consciencia de canal y de QoS** (*channel-aware / QoS-aware*): combina la información del canal con restricciones de retardo y tasa mínima por flujo. Representantes: M-LWDF, PSS.

Las categorías (iv) semi-persistent y (v) energy-aware se descartan por tener objetivos de optimización incompatibles con las métricas evaluadas.

II-D. Algoritmos evaluados

La Tabla I resume los ocho schedulers evaluados. En lugar de describir todos con el mismo esquema, vale la pena destacar sus diferencias conceptuales.

RR y BET son los más simples. RR no sabe nada del canal: turno por turno, igual para todos. BET agrega una sola idea: en lugar de igualar el tiempo, iguala el throughput recibido ($m_i = 1/\bar{r}_i$). La diferencia práctica es que BET da más tiempo a los usuarios con peor canal para compensar — algo que RR nunca haría.

MT y TTA explotan el canal pero de formas distintas. MT es directo: $m_i = r_i(t)$, siempre gana quien tiene mejor CQI en ese instante. TTA normaliza por la tasa wideband del mismo

Cuadro I: Schedulers evaluados — esquema 2-3-2 de la taxonomía Capozzi

Sched.	Cat.	Clase ns-3	Característica
RR	(i)	RrFfMacScheduler	Tiempo igual por UE
BET	(i)	FdBetFfMacScheduler	Throughput igual
MT	(ii)	TdMtFfMacScheduler	Maximiza tasa inst.
TTA	(ii)	TtaFfMacScheduler	Normaliza por tasa wide-band
PF	(ii)	PfFfMacScheduler	Proporcional histórico
M-LWDF	(iii)	MlwdFfMacScheduler	HOL delay + canal
PSS	(iii)	PssFfMacScheduler	Separación GBR/BE

TTI ($m_i = r_i(t)/R_c(t)$), lo que mide la *ventaja relativa* de asignar un RB específico a un usuario. La diferencia es importante bajo fading: MT siempre favorece a quien está cerca de la antena, mientras TTA puede favorecer a un usuario lejano si su canal instantáneo supera su propio promedio.

PF combina ambas ideas. Su métrica $m_i(t) = r_i(t)/\bar{r}_i(t)$ es esencialmente MT dividido entre BET: explota el canal (numerador) pero corrige por el historial acumulado (denominador). Es el algoritmo que más aparece en la literatura como referencia, y los resultados confirman por qué: equilibra eficiencia y equidad sin configuración adicional.

M-LWDF extiende PF con un tercer factor: el delay del paquete al frente del buffer (D_i^{HOL}) ponderado por la urgencia del flujo ($-\log \delta_i$): $m_i = -\log \delta_i \cdot D_i^{HOL} \cdot r_i(t)/\bar{r}_i(t)$. Para flujos best-effort el término extra es constante y M-LWDF se comporta idéntico a PF. La diferencia aparece solo cuando hay flujos GBR con paquetes acumulados [5] — lo que hace que los resultados de T1 y T2 sean tan distintos.

PSS ataca el problema diferente: en lugar de una métrica única, separa el scheduler en dos etapas. Primero (TDPS) identifica los UEs GBR con delay elevado y los saca de la competencia general; luego (FDPS) aplica PF entre los demás. La separación explícita evita que un flujo de video compita en la misma métrica que una descarga de fondo [6], algo que M-LWDF resuelve implícitamente escalando el peso del delay.

III. ESTADO DEL ARTE

La referencia más influyente sigue siendo Capozzi et al. [1], que evaluaron doce schedulers con distribución uniforme de usuarios y tráfico full-buffer. Sus resultados para PF reportan Jain claramente superior al 0.747 que observamos aquí con fading EPA activo. La diferencia no es menor: sin fading, los UEs equidistantes tienen CQI idéntico y PF se comporta casi como RR. Con fading real, PF explota la diversidad temporal y favorece a quien tiene mejor canal *en ese instante*, lo que degrada la equidad global. El fading EPA es una condición más realista pero más hostil para la equidad.

Andrews et al. [5] propusieron M-LWDF originalmente para redes 1xEV-DO, con foco en mantener la tasa de pérdida de paquetes por debajo de un umbral estadístico. Su extensión a LTE demostró ventajas en latencia para flujos de video, aunque los experimentos originales usaban modelos de tráfico ON-OFF con tasas moderadas — muy distintas al escenario de saturación total que evaluamos aquí.

PSS [6] introduce la idea de separar el scheduler en dos etapas (TDPS para GBR, FDPS para el resto), que en teoría permite servir a ambas clases sin competencia directa. En la práctica, los resultados de Sesia et al. muestran ventajas principalmente bajo carga media; bajo saturación plena, la separación no es tan clara porque los recursos del FDPS se agotan rápidamente.

Trabajos más recientes comparan schedulers bajo heterogeneidad de tráfico [7], [8], pero normalmente con N fijo y distribución uniforme, o con distribución clusterizada pero tráfico homogéneo. No encontramos ninguno que cruce ambas dimensiones —distribución espacial y mezcla de tráfico— sobre la taxonomía completa, con 20 repeticiones estadísticas por configuración para controlar la varianza del fading.

IV. METODOLOGÍA

IV-A. Entorno de simulación

Usamos ns-3.47 [9] con módulo LTE/EPC (Tabla II). El módulo LTE de ns-3 implementa el stack completo de protocolo descendente (PHY, MAC, RLC, PDCP, EPC) y expone la interfaz FfMacScheduler que permite intercambiar el algoritmo de scheduling sin modificar el resto del simulador. Tres decisiones de configuración merecen justificación explícita.

Fading EPA en lugar de canal puramente determinístico. Sin fading, dos UEs a la misma distancia del eNB tienen CQI idéntico en cada TTI. PF se convierte casi en RR y las diferencias entre schedulers channel-aware se minimizan artificialmente. El modelo TraceFadingLossModel con traza EPA 3 km/h añade variación temporal por RB, lo que permite a MT y PF explotar diversidad multiusuario real. Sin esto, el experimento no tendría sentido.

Tráfico full-buffer en T1. Una versión temprana del experimento usó CBR a 1 Mbps por usuario. El resultado fue que en varios TTIs la cola de algunos UEs estaba vacía —el scheduler no tenía qué asignar— y las diferencias entre algoritmos desaparecían en el ruido. Cambiar a OnOff always-on a 10 Mbps/UE garantiza que la demanda supera siempre la capacidad de la celda (≈ 20 Mbps), forzando al scheduler a elegir activamente en cada TTI.

Asignación interleaved en T2. Si los UEs de video se concentran en un cluster y los BE en otro, es imposible separar si un scheduler favorece video porque es QoS-aware o simplemente porque esos UEs están más cerca de la antena. La asignación u mód 3 mezcla los tres tipos en cada cluster, haciendo la posición y el tipo de tráfico estadísticamente independientes.

IV-B. Variables independientes y escenarios

Distribución espacial:

- **D1 — Uniforme:** UEs distribuidos uniformemente en disco de radio 490 m.
- **D2 — Clusterizada:** 3 clusters a distancias diferenciadas del eNB ($C1=100$ m, $C2=250$ m, $C3=400$ m), radio de cluster 70 m, ángulos separados 120° . Implementa la condición de canal heterogéneo explícitamente requerida.

Tipo de tráfico:

Cuadro II: Parámetros fijos de simulación

Parámetro	Valor
Simulador	ns-3.47, módulo LTE
eNodeBs	1 (celda única)
Potencia TX eNB	46 dBm
Frecuencia DL	2.1 GHz (EARFCN 100)
Ancho de banda DL	10 MHz $\rightarrow$ 50 RBs
Path loss	Log-distance, $\alpha=3.5$
Fading	TraceFadingLossModel EPA 3 km/h
CQI	Dinámico, full-bandwidth, 1 TTI
EPC	PointToPointEpcHelper
Protocolo	UDP extremo a extremo
Duración	30 s (warmup 5 s descartado)
Semilla RNG	SetSeed(12345), SetRun(<i>runId</i>)

- **T1 — Homogéneo:** todos los UEs con tráfico full-buffer (OnOff a 10 Mbps). Capacidad ofrecida $\gg$ capacidad de celda (≈ 20 Mbps), garantizando saturación.
- **T2 — Heterogéneo:** asignación intercalada (u mód 3): video GBR (flujo con tasa mínima garantizada de 1.5 Mbps, QCI-4), gaming GBR (64 kbps, QCI-3) y best-effort (sin garantía, full-buffer). La asignación interleaved garantiza que cada cluster recibe los tres tipos mezclados, eliminando correlación posición-tráfico.

IV-C. Diseño experimental

El experimento completo comprende dos grupos:

- **Grupo A** ($H1, H2$): 7 schedulers $\times$ D1/D2 $\times$ $N \in \{10, 20, 40\} \times T1 \times 20$ runs = **840 corridas**.
- **Grupo B** ($H3, H4$): 7 schedulers $\times$ D1/D2 $\times$ $N \in \{10, 20, 40\} \times T2 \times 20$ runs = **840 corridas**.

Total: 1,680 corridas. Cada configuración utiliza 20 repeticiones con semillas independientes para obtener IC al 95 % (t-Student, $df = 19$, $t_{crit} = 2,093$). Las comparaciones entre schedulers emplean el test de Welch (varianzas no iguales) con umbral $p < 0,05$. La normalidad de los datos fue verificada con la prueba de Shapiro-Wilk en las métricas principales (todas con $p > 0,14$), lo que valida el uso del análisis paramétrico. No se detectaron valores atípicos (z-score $< 2,5$ en todos los grupos).

IV-D. Hipótesis de investigación

- H1:** Los schedulers orientados a throughput presentan degradación no lineal de fairness bajo distribución clusterizada.
- H2:** La heterogeneidad espacial tiene mayor impacto sobre fairness que el número de usuarios.
- H3:** Los schedulers balanceados (PF) pierden eficiencia espectral cuando coexisten flujos GBR y best-effort.
- H4:** Los schedulers híbridos (M-LWDF, PSS) mejoran el compromiso fairness-throughput frente a PF bajo tráfico heterogéneo.

V. RESULTADOS

V-A. Escenario de referencia ($N=20$, D1, T1)

Antes de analizar los efectos de la heterogeneidad, vale la pena observar el escenario más simple: distribución uniforme, tráfico homogéneo, $N=20$. Las figuras de este trabajo muestran

Cuadro III: Métricas de referencia — N=20, D1, T1 (media $\pm$ IC 95 %)

Scheduler	Cat.	Tput [Mbps]	Jain	UEs activos
RR	(i)	7.22 $\pm$ 0.60	0.642 $\pm$ 0.040	20/20
BET	(i)	4.32 $\pm$ 0.27	0.999 $\pm$ 0.000	20/20
MT	(ii)	11.09 $\pm$ 0.19	0.116 $\pm$ 0.023	$\approx$ 7/20
TTA	(ii)	10.04 $\pm$ 0.68	0.777 $\pm$ 0.035	20/20
PF	(ii)	14.16 $\pm$ 0.84	0.747 $\pm$ 0.023	20/20
M-LWDF	(iii)	14.16 $\pm$ 0.84	0.747 $\pm$ 0.023	20/20
PSS	(iii)	14.53 $\pm$ 0.91	0.707 $\pm$ 0.033	20/20

Cuadro IV: Distribución de throughput por usuario — D2, N=20, T1 (run representativo)

Scheduler	Mín [Mbps]	Máx [Mbps]	Rango	UEs>0
RR	0.153	1.210	1.057	20/20
BET	0.278	0.295	0.017	20/20
MT	0.000	4.681	4.681	7/20
TTA	0.337	1.768	1.431	20/20
PF	0.361	1.846	1.485	20/20
M-LWDF	0.361	1.846	1.485	20/20
PSS	0.341	2.105	1.764	20/20

también resultados de CQA (*Channel and QoS Aware*), un octavo scheduler evaluado como extensión de la categoría (iii); su análisis detallado se presenta en el reporte de análisis complementario al paper. Los números de la Tabla III cuentan una historia ya conocida pero que el fading con full-buffer hace más nítida.

MT alcanza 11.09 Mbps —nada mal— pero en la práctica está sirviendo a apenas 7 de 20 usuarios en promedio (el rango observado entre las 20 repeticiones va de 5 a 9). Los demás reciben cero bytes durante los 25 segundos de medición. Es la versión más cruda del trade-off throughput/fairness: el algoritmo hace su trabajo perfectamente, maximiza la tasa instantánea, y en el proceso convierte la celda en un monopolio. BET es el extremo opuesto: Jain=0.999 es casi perfectamente justo, pero a costa de bajar el throughput de celda a 4.32 Mbps. PF, con 14.16 Mbps y Jain=0.747, es el equilibrio que la mayoría de los operadores elegiría por defecto.

Lo que llama la atención de esta tabla es que PF y M-LWDF producen exactamente los mismos números bajo T1. Tiene sentido: M-LWDF es PF más un término de delay HOL. Con tráfico full-buffer todos los paquetes tienen delay similar, así que el término extra no cambia nada. M-LWDF solo se diferencia cuando hay flujos con restricciones de latencia distintas, es decir, bajo T2.

Throughput por usuario (D2, N=20, T1). La Tabla IV muestra cómo se distribuye el throughput entre los 20 UEs bajo distribución clusterizada. Es la métrica que el Jain resume en un escalar, pero la distribución completa es más reveladora. MT tiene rango máximo-mínimo de 4.68 Mbps (mejor cluster) a 0 Mbps (peor cluster). BET reduce ese rango a 0.017 Mbps, a costo de que el máximo cae de 4.68 a 0.295 Mbps. PF equilibra: rango de 1.49 Mbps (de 0.36 a 1.85), todos los UEs reciben algo.




Figura 1: Throughput de celda vs N (D1, T1). PF sube de forma estable; PSS alcanza su máximo en N=20 y baja en N=40; BET cae porque dedica más tiempo a UEs de canal débil.

V-B. H1: Fairness bajo distribución clusterizada

La predicción de H1 era que los schedulers orientados a throughput degradarían su fairness al pasar de distribución uniforme (D1) a clusterizada (D2). Las Figs. 2 y 3 muestran la realidad, que es más interesante que la predicción.

MT tiene Jain bajo en D1 (0.116) y también en D2 (0.135). La starvation ya existía en D1 porque el fading instantáneo siempre favorece a unos pocos UEs; con clusters, la ventaja de los UEs cercanos se vuelve persistente en lugar de rotatoria, pero el Jain total no cae significativamente ($p = 0.23$). MT ya estaba en el suelo. No hay mucho más que caer.

Más revelador es TTA: es el único scheduler cuya curva de Jain vs N cambia de pendiente entre D1 y D2 (Fig. 3). En distribución uniforme, agregar usuarios mejora marginalmente el Jain de TTA (tiene más candidatos para normalizar por tasa wideband). Con clusters, agregar usuarios empeora la situación porque los UEs distantes arrastran el promedio wideband hacia abajo sin recibir recursos a cambio. PF y M-LWDF, en cambio, muestran curvas casi indistinguibles entre D1 y D2: el historial proporcional compensa la desventaja de canal sin que el operador tenga que configurar nada.

La Fig. 4 resume el efecto para N=20. La barra de MT en D2 apenas se mueve respecto a D1 —ambas son igualmente malas. PF y M-LWDF tienen barras prácticamente idénticas entre distribuciones.

H1 se confirma parcialmente: la *starvation* (privación total de recursos) bajo D2 existe y es sistemática para MT —los usuarios del cluster más lejano (C3, 400 m) no reciben nada de forma consistente— pero el índice de Jain global no lo captura bien porque MT ya era injusto en D1. La degradación más clara de H1 aparece en TTA, no en MT.




Figura 2: Jain vs N (D1, T1). MT colapsa con N (de 0.18 a 0.06). TTA mejora levemente con más usuarios; PF se mantiene estable en 0.75.




Figura 3: Jain vs N (D2, T1). TTA es el único que cambia de pendiente respecto a D1.

V-C. H2: Efecto espacial vs número de usuarios

Esta hipótesis nos salió mal. Anticipábamos que pasar de distribución uniforme a clusterizada (D1→D2) impactaría más en la equidad que triplicar el número de usuarios (N=10→40). La Tabla V muestra lo contrario para 6 de 7 schedulers.

La explicación más plausible: PF, M-LWDF y TTA normalizan el CQI instantáneo por un historial promedio. Un UE en C3 (400 m, SINR bajo) tiene un historial bajo, pero su ratio instantáneo/histórico puede ser tan competitivo como el de uno en C1 cuando el fading lo favorece. El historial actúa como igualador automático de ventajas de canal. Agregar más usuarios, en cambio, satura progresivamente la celda y hace más difícil servir a todos —ahí sí hay un deterioro consistente.

Para MT la diferencia es aplastante: $\Delta J_{carga} = 0,121$ vs




Figura 4: Jain D1 vs D2, N=20, T1. MT tiene fairness mala en ambas condiciones.

Cuadro V: ¿Qué impacta más la equidad: la distribución o la carga?

Scheduler	$ \Delta J $ espacial	$ \Delta J $ carga	Domina
RR	0.009	0.024	Carga
BET	0.000	0.001	Carga
MT	0.020	0.121	Carga
TTA	0.048	0.047	Espacial
PF	0.000	0.011	Carga
M-LWDF	0.000	0.011	Carga
PSS	0.015	0.053	Carga

$\Delta J_{espacial} = 0,020$. Triplicar los usuarios es seis veces más dañino para la equidad de MT que pasar a clusters. Con N=40 hay 40 candidatos para el mejor canal en cada TTI: las chances de que un mismo usuario gane dos TTIs consecutivos son mínimas, pero la probabilidad de que los del cluster C3 nunca ganen sube.

El único scheduler donde el efecto espacial marginalmente domina es TTA, por las razones descritas en H1. Es el único cuya métrica de normalización (tasa wideband del mismo TTI) no acumula historial y por tanto no compensa la desventaja geográfica tan eficientemente.

Dicho de otra forma: antes de ajustar la distribución antena-usuario, vale más revisar si la celda está saturada. PF absorbe la heterogeneidad espacial sin necesitar configuración adicional de umbrales o parámetros de distancia.

V-D. Un hallazgo no anticipado: D2 mejora el throughput

Al revisar los datos de throughput en D2 (Tabla VI), encontramos algo que no estaba en las hipótesis originales: pasar de distribución uniforme a clusterizada *aumenta* el throughput de celda para los schedulers channel-aware. PF pasa de 14.16 Mbps en D1 a 19.36 Mbps en D2. PSS sube de 14.53 a 20.30 Mbps, prácticamente el límite teórico de la celda con 10 MHz de BW.

La explicación: en D1, parte de los recursos va a UEs en los 400–490 m de radio, que tienen SINR≈0 dB y convierten cada RB en apenas 2 bits. En D2, PF sigue distribuyendo recursos proporcionalmente, pero ahora la mayoría va al cluster C1

Cuadro VI: Throughput de celda D1 vs D2 (N=20, T1). Los schedulers channel-aware ganan eficiencia con clusters.

Scheduler	D1 [Mbps]	D2 [Mbps]	Cambio
RR	7.22	11.35	+57 %
BET	4.32	5.97	+38 %
MT	11.09	11.09	0 %
TTA	10.04	13.71	+37 %
PF	14.16	19.36	+37 %
M-LWDF	14.16	19.36	+37 %
PSS	14.53	20.30	+40 %




Figura 5: Throughput total: T1 vs T2 (N=20, D1). La paradoja: M-LWDF cae más que cualquier otro.

(100 m, SINR $\approx$ 15-20 dB), que convierte cada RB en 6–8 bits. El historial de PF compensa la desigualdad entre clusters, pero no puede igualar totalmente a UEs con 15 dB de diferencia de SINR. El resultado neto es que los mismos 50 RBs generan más throughput porque van principalmente a un canal eficiente.

MT es la excepción: su throughput no cambia entre D1 y D2 (11.09 Mbps en ambos) porque ya maximizaba eficiencia en D1 eligiendo al mejor UE cada TTI. En D2 elige los mismos UEs de C1, con el mismo resultado. Lo que cambia es que los UEs de C3 dejan de recibir nada incluso ocasionalmente.

Esto complica parcialmente el diagnóstico de H2: la distribución espacial no solo no daña la equidad de los schedulers robustos, sino que mejora su eficiencia. El motivo por el que la carga domina sobre la distribución en la Tabla V no es que D2 sea irrelevante, sino que PF y M-LWDF se benefician de la estructura de canal de D2.

V-E. H3: Efecto del tráfico heterogéneo

Aquí aparece el resultado más contraintuitivo del trabajo. Al introducir tráfico heterogéneo (T2), el throughput de celda cae en todos los schedulers (Fig. 5). Lo esperable. Lo inesperado es *quién cae más*: M-LWDF baja un 31.2 % y PSS un 26.9 %, mientras que MT —el más agresivo en maximizar throughput— casi no se mueve (-1.2 %).

La razón es estructural. M-LWDF prioriza flujos según su delay head-of-line ponderado por la PLR objetivo. Los flujos GBR de video (1.5 Mbps) y gaming (64 kbps) tienen restricciones de delay muy estrictas, así que M-LWDF les asigna

F6 — GBR vs BE: efecto del scheduler QoS-aware (N=20, D1, T2)




Figura 6: Throughput GBR vs BE bajo T2. M-LWDF favorece GBR; PF no distingue entre tipos.

recursos agresivamente aunque tengan tasas bajas. El resultado: los flujos best-effort quedan relegados, y el throughput *total* de la celda cae porque se dedica capacidad a flujos de baja tasa que no la usan toda. M-LWDF hace exactamente lo que fue diseñado para hacer; el costo^{es} que el throughput agregado baja.

MT, en contraste, ignora completamente el tipo de bearer. Para él, un paquete de video y uno de BE son indistinguibles: solo importa el CQI instantáneo. Por eso su throughput apenas cambia entre T1 y T2. Claro que tampoco cumple los SLA de los flujos GBR, pero eso no aparece en el throughput total.

La Fig. 6 lo hace explícito: M-LWDF y PSS transfieren capacidad desde BE hacia GBR. PF distribuye ambos proporcionalmente sin distinguirlos.

La diferencia entre T1 y T2 para PF es estadísticamente significativa ($t = +4.96$, $p < 0.001$, $d = 1.57$), y H3 se confirma. Pero hay un efecto adicional que el throughput total no muestra: el Jain también cae drásticamente al pasar a T2. PF pierde un 24.9 % de equidad (de 0.747 a 0.561), M-LWDF un 24.5 %, y hasta BET cae un 14.3 % (de 0.999 a 0.856). La causa es estructural: con 1/3 de usuarios en gaming (64 kbps) y 1/3 en video (1.5 Mbps), la distribución de throughput por usuario es inherentemente desigual por las diferencias de tasa máxima —sin importar qué scheduler se use. El tráfico heterogéneo no solo reduce la eficiencia de la celda; también degrada la equidad global porque las tasas garantizadas de GBR son muy distintas entre sí y mucho menores que las del best-effort.

Otro dato notable: MT es el único scheduler con PLR $\approx$ 0 bajo T1. Al no generar cola de espera (siempre sirve al mejor UE en el instante), los paquetes se transmiten sin retardo ni pérdida —a costa de dejar a 13 usuarios sin servicio.

V-F. H4: Schedulers QoS-aware bajo tráfico heterogéneo

La Fig. 7 es la más interesante del paper. Muestra el índice de Jain bajo T2 —tráfico heterogéneo— para D1 y D2. Cuando los usuarios están distribuidos uniformemente (D1), los tres

F8 — Fairness bajo tráfico heterogéneo: D1 vs D2 (N=20, T2)




Figura 7: Jain bajo T2: M-LWDF y PSS *mejoran* con D2; PF empeora. Las líneas se cruzan.

Cuadro VII: Welch *t*-test: Jain T2, N=20, D2. El efecto M-LWDF/PSS vs PF es grande.

Comparación	$\bar{A}$	$\bar{B}$	p	d
M-LWDF vs PF	0.596	0.543	<0.001	+5.14
PSS vs PF	0.596	0.543	<0.001	+4.72
PSS vs M-LWDF	0.596	0.596	0.953	+0.02

schedulers QoS-aware tienen Jain similar: PF 0.561, M-LWDF 0.564, PSS 0.553. La diferencia es mínima y no significativa.

Cuando los usuarios están clusterizados (D2), las líneas se separan. PF baja a 0.543. M-LWDF y PSS suben a 0.596. La brecha es estadísticamente sólida ($p < 0,001$, $d \approx 5$; Tabla VII).

Un dato adicional que confirma la solidez del resultado: el throughput de celda bajo T2 también aumenta al pasar de D1 a D2, igual que bajo T1 (PF: +32.3 %, M-LWDF: +33.7 %, PSS: +33.8 %). El beneficio de eficiencia del clustering es independiente del tipo de tráfico.

Por qué M-LWDF y PSS *mejoran* su Jain al pasar a D2: con distribución interleaved, cada cluster tiene un tercio de flujos GBR. Los UEs GBR en C3 (400 m, canal débil) acumulan delay HOL rápidamente porque PF no les da prioridad. M-LWDF escala su prioridad precisamente cuando ese delay crece, así que los UEs de C3 eventualmente reciben recursos aunque su canal sea malo. Al servir a más UEs distantes, el Jain global sube. PF no tiene ese mecanismo: como el canal de C3 siempre pierde contra C1 en la métrica proporcional, sus UEs quedan rezagados.

El retardo E2E (Fig. 8) no diferencia entre schedulers de forma significativa (todos en torno a 3.2–3.3 ms). Eso está muy por debajo de los SLA de gaming (50 ms) y video (300 ms). Bajo la carga y el número de usuarios evaluados, el cuello de botella está en el canal, no en el buffer del scheduler. Esto puede cambiar con $N > 40$ o con interferencia inter-celda, donde el retardo RLC se puede acumular.

Una nota sobre PLR. Los datos muestran que M-LWDF

F7 — Delay E2E: D1 vs D2 (N=20, T2 heterogéneo)




Figura 8: Retardo E2E: D1 vs D2 (N=20, T2). Ningún scheduler viola los SLA de latencia.

tiene PLR ligeramente más alta que PF y PSS tanto en D1 como en D2 (0.0066 vs 0.0048 en D1; 0.0040 vs 0.0029 en D2). Esto parece contradecir la idea de que M-LWDF es "más QoS-aware". La explicación está en que la PLR que medimos es un promedio global sobre todos los flujos —GBR y BE—. M-LWDF protege agresivamente los flujos GBR pero deja que los flujos BE acumulen retardo y eventualmente pierdan paquetes. PSS tiene mecanismo similar pero más conservador. La conclusión es que para evaluar correctamente el beneficio de M-LWDF en QoS habría que medir la PLR por tipo de flujo, no la PLR global. Con la instrumentación actual (FlowMonitor sin etiquetado por bearer) eso requeriría correlacionar flujos IP con el tipo de tráfico via análisis de dirección —trabajo que dejamos para una extensión.

VI. DISCUSIÓN

El resultado más claro de este trabajo no es cuál scheduler es mejor —eso depende del escenario— sino cuáles supuestos del diseño del scheduler determinan su comportamiento bajo heterogeneidad.

PF es robusto porque normaliza por historial propio: si un UE lleva varios TTIs sin recursos, su ratio instantáneo/histórico sube y eventualmente le toca. Es una forma de equidad que no requiere conocer el tipo de tráfico ni configurar umbrales. El precio es que no distingue entre un paquete de video con restricción de latencia y uno de descarga en segundo plano.

M-LWDF añade exactamente esa distinción: el delay HOL pondera la prioridad según urgencia. Pero hacerlo tiene un costo en throughput total cuando el tráfico GBR tiene tasas garantizadas bajas —el scheduler dedica recursos a flujos que no los usan completamente, y el best-effort no puede aprovechar ese margen.

Lo que más nos sorprendió al analizar los resultados es el comportamiento de BET bajo saturación. Jain=0.999 en todas

las condiciones, incluyendo D2 con clusters, y con cualquier N de 10 a 40. BET logra equidad perfecta siendo ignorante del canal: simplemente acumula throughput histórico por UE y da recursos a quien menos ha recibido. El costo —4.3 Mbps de throughput frente a los 14.5 Mbps de PSS— es enorme para un escenario de datos masivos. Pero no todo escenario necesita maximizar throughput.

MT es el único que no debería usarse en una celda heterogénea con múltiples servicios. En D2 con tráfico interleaved (T2), alrededor de 10 de 20 UEs reciben cero bytes durante la mayor parte de la simulación —en D1 con tráfico homogéneo la cifra sube a 14/20 starved (solo 6 activos, Tabla III). Con T2, algunos flujos GBR de baja tasa (gaming, 64 kbps) generan menos presión en el buffer, y MT puede servirlos ocasionalmente cuando los UEs de C1 no tienen backlog. Pero eso no cambia el diagnóstico estructural: MT nunca prioriza a un UE lejano si hay uno cercano con mejor CQI, y en D2 los UEs de C1 siempre tienen mejor canal promedio.

VI-A. Implicaciones para el diseño de redes

Antes de hablar de 5G y sus tipos de servicio, conviene entender qué significa cada número en términos concretos. PSS en D2 con tráfico homogéneo alcanza 20.30 Mbps —prácticamente el límite de la celda con 10 MHz de BW— con Jain>0.69. Traducido: la mayoría de los 20 usuarios recibe más de 1 Mbps sostenido. PF no llega tan alto en throughput (19.36 Mbps) pero es 8 % más justo (Jain=0.747). Para una aplicación de banda ancha donde el rendimiento individual importa tanto como el agregado, la diferencia entre PSS y PF no es obvia. Depende de si el operador quiere maximizar la celda o la experiencia mínima garantizada.

Para escenarios del tipo *eMBB* (banda ancha mejorada), PF es la opción menos riesgosa: no requiere configurar umbrales de QoS, es robusto a la carga —su throughput sube de 14.06 a 14.44 Mbps al pasar de N=10 a N=40, mientras PSS cae de 14.17 a 13.87 Mbps— y su Jain se mantiene estable independientemente de la distribución geográfica de los usuarios.

La discusión de URLLC es más matizada. Todos los schedulers cumplen los SLA de latencia en las condiciones evaluadas (delay $\approx$ 3.2 ms, muy por debajo de 50 ms para gaming). Eso sugiere que con 20 UEs y saturación moderada, el cuello de botella no está en el scheduler sino en el canal. M-LWDF es el candidato natural para cuando eso cambie —carga alta, N>40— porque el delay HOL escala la prioridad de un flujo conforme sus paquetes envejecen, algo que PF no hace. El precio ya lo conocemos: mayor PLR global (0.0066 vs 0.0048 de PF).

El caso más claro es el de los sensores IoT (*mMTC*). BET logra Jain>0.999 sin importar cuántos dispositivos hay ni dónde están. MT, por el contrario, ignora sistemáticamente a los sensores en zonas de cobertura débil —algo inaceptable si esos sensores miden temperatura en una subestación o presión en una tubería. Que BET tenga un throughput de celda tres veces menor que PF no importa si cada sensor solo necesita transmitir 100 bytes cada 30 segundos.

La pregunta práctica es si un operador puede cambiar el scheduler según el perfil de la celda. Los datos de H2 sugieren que sí, y que la geometría de la celda no es el factor que más importa para esa decisión: lo que domina es la carga y el tipo de tráfico. PF bajo carga homogénea, M-LWDF o PSS cuando hay flujos GBR activos. Y si la celda tiene principalmente IoT de baja tasa, BET probablemente funcione mejor que cualquier alternativa channel-aware.

VI-B. Sobre las limitaciones del estudio

Usar una sola celda con usuarios estáticos es la decisión de diseño que más condiciona qué se puede concluir. No es que sea un error metodológico —es exactamente lo que se necesita para aislar los efectos del scheduler de la interferencia inter-celda, la movilidad y el handover— pero sí limita hasta dónde se pueden extender los resultados.

La interferencia inter-celda es lo que más podría cambiar el ranking. Un UE en C3 (400 m) ya tiene SINR bajo con su propia celda; con interferencia de vecinas, su SINR puede volverse negativo. En ese escenario, M-LWDF podría verse amplificado —más urgencia de delay HOL para el UE afectado— o irrelevante si el canal está tan degradado que ninguna priorización ayuda. No tenemos forma de predecir cuál de los dos efectos dominaría sin correrlo.

La movilidad estática favorece a los schedulers con historial largo (PF). En un escenario vehicular donde el canal cambia sustancialmente entre TTIs, el historial acumulado de PF puede quedar desactualizado —se estaría optimizando para el canal que el usuario *tenía*, no el que tiene ahora. TTA, que normaliza por la tasa wideband del TTI actual, podría resultar más robusto bajo alta movilidad. Queda como hipótesis para trabajos futuros.

VII. CONCLUSIONES

La pregunta central de este trabajo era si existe algún scheduler capaz de satisfacer simultáneamente throughput, equidad y QoS en una celda heterogénea. La respuesta directa es no. Ninguno de los siete algoritmos evaluados domina en todas las métricas bajo todas las condiciones. Lo que sí existe son schedulers mejores para contextos específicos.

Si el tráfico es homogéneo y la prioridad es eficiencia con equidad razonable, PF sigue siendo la elección correcta. No requiere configuración de parámetros de QoS, es robusto a la distribución espacial de los usuarios, y su rendimiento es prácticamente indistinguible de M-LWDF cuando no hay restricciones de latencia diferenciadas.

Si el tráfico mezcla flujos GBR con best-effort, y especialmente si los usuarios están agrupados en zonas de distinta calidad de canal, M-LWDF y PSS ofrecen una ventaja real en equidad global ($p < 0,001$, $d \approx 5$). La ganancia no es gratuita: ambos reducen el throughput total entre un 27 y un 31 % porque priorizan flujos de baja tasa. Esa es exactamente la decisión que el diseño de redes 5G con network slicing debería automatizar: asignar distintos schedulers a distintos slices según el perfil de tráfico dominante del slice, en lugar de usar uno universal.

El resultado más valioso —porque no lo anticipamos— es doble. Primero: la carga de la celda afecta más la equidad que la distribución geográfica de los usuarios para 6 de 7 schedulers. Segundo: la distribución clusterizada en realidad *mejora* el throughput de los schedulers channel-aware (PF +37 %, PSS +40 % de D1 a D2) porque concentra los recursos en UEs de canal eficiente. El clustering no es el problema que asumíamos; el problema es la carga.

Quedan tres preguntas relevantes para trabajo futuro. Primera: ¿cómo cambia el ranking con interferencia inter-celda? En redes densas, M-LWDF podría ver ampliada su ventaja (más urgencia de delay HOL) o neutralizada (SINR demasiado baja para que cualquier scheduler ayude). Segunda: ¿qué pasa con $N > 40$? Los datos sugieren que PF mantiene throughput estable mientras MT lo mantiene también —la curva de throughput de MT es casi plana con N — pero el Jain de MT cae linealmente con N . Eventualmente habría un cruce donde M-LWDF o PSS superan también a MT en throughput bajo alta carga heterogénea. Tercera: ¿es viable un scheduler adaptativo que cambie entre PF y M-LWDF según la fracción de tráfico GBR detectada en tiempo real? Los resultados sugieren que sería beneficioso y los parámetros de decisión están bien definidos por los datos de este trabajo.

AGRADECIMIENTOS

Los experimentos descritos en este trabajo requirieron aproximadamente 30 horas de cómputo distribuido, ejecutando 2,040 simulaciones en ns-3.47. El autor agradece al grupo de Redes de Computadoras de la BUAP por el acceso a la infraestructura utilizada, y a los desarrolladores de ns-3 por mantener un simulador de acceso libre con módulo LTE completo y bien documentado.

REFERENCIAS

- [1] F. Capozzi, G. Piro, L. A. Grieco, G. Boggia, and P. Camarda, "Downlink packet scheduling in LTE cellular networks: Key design issues and a survey," *IEEE Communications Surveys & Tutorials*, vol. 15, no. 2, pp. 678–700, 2013.
- [2] P. Viswanath, D. N. C. Tse, and R. Laroia, "Opportunistic beamforming using dumb antennas," *IEEE Transactions on Information Theory*, vol. 48, no. 6, pp. 1277–1294, 2002, formaliza el concepto de diversidad multiusuario explotada por schedulers PF.
- [3] 3GPP, "Evolved universal terrestrial radio access (E-UTRA); physical layer procedures," 3rd Generation Partnership Project, Tech. Rep. TS 36.213, 2018.
- [4] R. Jain, D. M. Chiu, and W. Hawe, "A quantitative measure of fairness and discrimination for resource allocation in shared computer systems," *DEC Research Report TR-301*, 1984.
- [5] M. Andrews, K. Kumaran, K. Ramanan, A. Stolyar, P. Whiting, and R. Vijayakumar, "Providing quality of service over a shared wireless link," *IEEE Communications Magazine*, vol. 39, no. 2, pp. 150–154, 2001.
- [6] S. Sesia, I. Toufik, and M. Baker, *LTE: The UMTS Long Term Evolution — From Theory to Practice*, 1st ed. Wiley, 2009.
- [7] R. Basukala, H. A. Mohd Ramli, and K. Sandrasegaran, "Performance analysis of EXP/PF and M-LWDF in downlink 3GPP LTE system," in *Proceedings of the 1st Asian Himalayas International Conference on Internet (AHICI)*, 2009, pp. 1–5.
- [8] A. Pokhariyal, T. E. Kolding, and P. E. Mogensen, "Performance of downlink frequency domain packet scheduling for the UTRAN long term evolution," *Proc. 17th IEEE PIMRC*, pp. 1–5, 2006.
- [9] ns-3 Consortium, "ns-3 network simulator, version 3.47," <https://www.nsnam.org>, 2024.